

Plano de Dados Reais

O que fica, o que muda e o que sai do que a Tribo 3 já construiu, mais a arquitetura completa de migração para dados públicos reais: fontes, calibração e riscos metodológicos.

v2 · 30 set 2026 | 8 passos cobertos | 10 fontes catalogadas | registro de execução incluso

EM UMA FRASE

A massa de participantes continua sintética — não existe base pública de participante de fundo de previdência no Brasil, e o Passo 1 precisa de gabarito conhecido para medir a limpeza — mas agora ela é **calibrada ano a ano com mortalidade real** (SIM+IBGE) em vez de pesos arbitrários, e os cenários econômicos passam a ser **100% dado público** na calibração.

O que já existe: manter, mudar, tirar

O pivo é mais cirúrgico do que parece: só mexe no mecanismo de geração do Passo 1 e em algumas afirmações desatualizadas nos docs. A separação em camadas que já existia (geração / qualidade / modelagem / benchmark) é o que torna esse pivo barato.

MANTÉM — sem tocar

Passo 1 — estrutura de banco inteira

migrations/V1/V2/V3, R__dicionario_dados.sql, R__referencia_externa.sql — o schema bitemporal (participante, evento, exposicao...) não depende de como os valores são gerados por baixo. scripts/injetores.py, regras.py, pipeline_qualidade.py — a injeção de erros e as 9 regras de qualidade são sobre qualidade de dado, não sobre realismo de mortalidade.

Passo 2 — praticamente tudo

avaliacao.py, comparar_modelos.py, cox_ph.py, kaplan_meier.py, survival_forest.py, registro.py, tests/test_survival.py — a metodologia inteira consome só tempo_observado/evento/covariáveis. Não importa se o dado por baixo ficou mais realista. A extração via --fonte banco continua igual.

Passo 3 — 100% intocado

Scripts de benchmark (IBGE/HMD/BR-EMS/SOA), arquivos em docs/referencias/ — já era real antes do professor pedir. Só ganha um papel novo, não muda código.

Passo 5 — toda a pipeline

taxas_brutas_qx.py, coortes.py, suavizacao.py, teste_aderencia.py, credibility.py, intervalos_confianca.py, validacao_temporal.py, tabua_propria.py, pipeline.py — nenhum desses sabe ou precisa saber como o Passo 1 gerou os eventos.

MUDA — não apaga, reescreve por dentro

ARQUIVO	O QUE SAI	O QUE ENTRA
ambiente-de-dados/scripts/gerar_dataset.py	Sorteio único de status_atual com pesos fixos (obito=5% global)	Simulação ano a ano com qx real por idade/sexo (SIM+IBGE)
ambiente-de-dados/docs/regras_geracao.md	Tabela de distribuições amostradas com números chutados	Mesma tabela, citando a fonte real de cada parâmetro (SIM+IBGE, AEPS/PREVIC, RAIS/CAGED)
ambiente-de-dados/DATASET_CARD.md	—	Seção nova: estrutura sintética por LGPD/gabarito; parâmetros calibrados com fonte real
tabua-biometrica-propria/scripts/comparacao_ae.py	IBGE como única referência de comparação	BR-EMS/SOA viram a validação principal (independente); IBGE vira checagem secundária
Docs do Passo 5 (data_card, model_card)	—	Seção declarando a fonte de calibração do Passo 1 e como a circularidade foi evitada
coletar_dados_publicos.py (Passo 4)	data_final=31/12/2024 fixo na coleta do Bacen; o docstring de nota_fontes_sem_api() sugere uma chamada do pacote pysus que está desatualizada (não é um import executado pelo script — é só texto de comentário)	Data até hoje; adicionar câmbio (série 1) e ETTJ; atualizar o texto do docstring para a API atual do pysus (from pysus.online_data import SIM)

SAI — de verdade (ou aposenta o uso, não o arquivo)

- Os números específicos dos pesos arbitrários (ativo 55%, aposentado 20%, desligado 15%, obito 5%, pensionista 5%) — não é o arquivo que sai, é esse conjunto de constantes que deixa de existir, substituído pela simulação calibrada.
- A fixture gerar_dados_locais do Passo 2 (survival-analysis/construir_dataset.py) — já era rotulada como não oficial. Com o Postgres calibrado sempre disponível, deixa de ser usada para gerar resultado reportável; pode continuar existindo só como utilidade de teste.
- Qualquer frase nos docs que hoje diz 'dado sintético, não reflete nada real' — vira desatualizada e precisa sumir ou virar 'estrutura sintética, parâmetros reais'.

NOVO — o que fica novo (não existia, precisa ser criado)

- Script de extração SIM+IBGE (série histórica multi-ano) — ainda não existe em lugar nenhum do repositório.
- A reformulação do gerador para simulação ano a ano — é o item mais trabalhoso de todo o pivo.

Duas camadas, uma dependendo da outra

A camada real vira o insumo de calibração e de validação; a camada sintética continua existindo porque é onde o Passo 1 injeta e mede erros de propósito — isso não tem substituto em dado real.

CAMADA REAL (pública, sem síntese)	ALIMENTA	CAMADA SINTÉTICA / MODELOS
SIM (óbitos) + IBGE (população)	calibra qx por idade/sexo — só nível, sem tendência	Gerador de participantes (Passo 1)
IBGE Tábua + HMD + BR-EMS + SOA	valida A/E — fonte independente da calibração	Passo 5 · Tábua própria
SIM + IBGE em série histórica	tendência real — challenger nacional	Passo 6 · Geracional (+ HMD)
Bacen SGS + ANBIMA ETTJ + Ibovespa	calibração + curva a termo	Passo 4 · Cenários econômicos
PREVIC Painei-Cidadão	valida % BD/CD/CV assumido	Gerador de participantes (Passo 1)

A linha do SIM/IBGE para o Passo 6 carrega só a tendência; a linha para o gerador carrega só o nível — separar as duas evita que o Passo 6 valide contra os mesmos dados que alimentaram a simulação.

Plano por passo

PASSO	DADO HOJE	DADO IDEAL	O QUE MUDA NA PRÁTICA
1	Pesos fixos arbitrários — obito=5% global, sem variar por idade	Estrutura sintética continua, mas o mecanismo vira simulação ano a ano com qx real por idade/sexo	Reescrever o algoritmo: simular sobrevivência ano a ano desde o ingresso. Óbito calibrado por SIM+IBGE; aposentadoria por AEPS/PREVIC; desligamento por RAIS/CAGED.
2	Roda sobre a massa arbitrária do Passo 1	Roda sobre a mesma massa, agora calibrada	Sem mudança estrutural. Ganha teste novo: checar se Cox/KM recuperam o padrão real de idade/sexo. Extensão opcional: ELSI-Brasil para 50+.
3	Já real: IBGE/HMD/BR-EMS/SOA	Mesmas fontes, mas vira validação independente da calibração do Passo 1	Sem mudança na coleta. Se o Passo 1 calibrar com SIM+IBGE, a comparação A/E não pode usar a mesma fonte sem virar circular.
4	Feito e testado: coletores reais de Bacen (6 séries) e Ibovespa, com snapshot auditado por hash. Artefato de calibração histórica versionado. Pendente: ETTJ/ANBIMA (spike experimental, não promovido)	Calibração histórica 100% real; trajetória futura ancorada na curva a termo real (ETTJ)	Selic/IPCA/CDI/IGP-M do Bacen SGS, câmbio já coletados de verdade. ETTJ da ANBIMA ainda experimental — resposta ao vivo não bateu com o contrato do spike, não foi promovida. Trajetória futura é sempre modelo, mesmo ancorada em dado real.

PASSO	DADO HOJE	DADO IDEAL	O QUE MUDA NA PRÁTICA
5	Experiência sintética vs. IBGE, um único ano	Mesma lógica, mais SIM+IBGE em série histórica como benchmark adicional	Enriquece a comparação A/E. Desacoplar fonte de calibração de fonte de validação — usar BR-EMS (principal, mesmo universo brasileiro) ou declarar fator de seleção explícito.
6	Feito: IBGE real (2015–2024) como challenger nacional primário, HMD como internacional secundário	Mesma lógica; Postgres (massa sintética) só como último recurso	Já funciona porque o Passo 1 calibra apenas o nível do qx, nunca a tendência — confirmado rodando o pipeline: resultado real de queda de mortalidade ($p=0,0073$), não ruído do sorteio.
7/8	—	Sem mudança de método, mas ganham responsabilidade nova	Com dado real na calibração (SIM), a seção de reidentificação do model card deixa de ser pro forma.

Ordem de execução e responsáveis

O plano por passo diz o que muda em cada um, mas não diz em que ordem nem de quem é cada tarefa nova — sem isso, cada dupla pode achar que dá pra começar sua parte isolada, quando a reformulação do Passo 1 é pré-requisito de fato para os demais.

FASE	QUEM	O QUE	BLOQUEIA / DEPENDE DE
1	Júlia Takaki Neves e Jefferson Sena Oliveira (Passo 1)	Feito e testado, incluindo o insumo do Passo 6: gerador reformulado para simulação ano a ano (qx real por idade/sexo, Tábua Completa do IBGE 2024) e o extrator de série histórica (<code>extrator_ibge_historico.py</code> , 2015–2024) que dá ao Passo 6 seu challenger nacional. Desvio deliberado do plano original: usa as tábuas prontas do IBGE em vez do microdado bruto do SIM (mesmo resultado, sem a fragilidade do pysus).	Não depende de nada. Bloqueava as Fases 2 e 3 inteiras — desbloqueado.
1 (paralelo)	Carlos Henrique de Souza Bispo e Paulo Henrique Virgílio Cerqueira (Passo 4)	Coletar Bacen SGS, ANBIMA ETTJ, Ibovespa — nada disso depende da massa do Passo 1.	Não depende de nada. Pode começar no mesmo dia que a Fase 1.
2	Caio Brandão Santos e Pedro Lucas Figueiredo Santana (Passo 2)	Rodar Cox/KM/RSF de novo sobre a massa calibrada; checar se recupera o padrão real de idade/sexo.	Depende da massa calibrada da Fase 1 estar pronta.

FASE	QUEM	O QUE	BLOQUEIA / DEPENDE DE
2	Maria Clara Oleari de Araujo e Guilherme Coelho Mendonça (Passo 5)	Feito: comparacao_ae.py ajustado — BR-EMS é agora a referência principal, IBGE virou diagnóstico explícito (Risco 02 resolvido). Pendente: rodar a pipeline inteira contra o Postgres real da equipe para confirmar os portões de qualidade (sem Docker/psql neste ambiente, só a lógica foi testada).	Depende da massa calibrada da Fase 1 estar pronta — já está.
2	Danielle Soares da Silva e Maria Eduarda Quaresma de Andrade (Passo 6)	Feito: pipeline reordenada para usar a série real do IBGE como fonte primária de tendência (Postgres virou último recurso, rotulado). Rodado de ponta a ponta: mortality improvement confirmado com dado real ($p=0,0073$).	Depende da massa calibrada da Fase 1 e do extrator de série histórica — os dois já estão prontos.
3	Leticia Arisa Kobayashi Higa e Victor Pontual Guedes Arruda Nóbrega (Passo 7/8)	Atualizar model cards com a seção nova de reidentificação; reexplicar os modelos re-treinados.	Depende dos modelos das Fases 1 e 2 já estarem re-treinados sobre dado calibrado.

Registro de execução — o que já foi feito, com evidência

Corte em 30 set 2026, sobre a branch `develop` (merges de `ambiente-de-dados-novo` e `feat/cenarios-economicos-v2`). Não é mais um plano — é o que foi lido no código e nos testes de fato, `commit` a `commit`.

FRENTE	STATUS	FEITO E VERIFICADO	PENDENTE
Passo 1 · gerador Júlia / Jefferson	feito	<code>gerar_dataset.py</code> reescrito: simulação ano a ano, qx real por idade/sexo (IBGE 2024, fator de seleção 0,85×) via novo módulo <code>calibracao.py</code> . Testado com 300 participantes (9 óbitos) e depois 3.000 (147 óbitos, razões de 1,0× a 2,2× contra a BR-EMS). Extrator de série histórica (<code>extrator_ibge_historico.py</code>) rodado de verdade contra o FTP do IBGE: 2015–2024, 2.491 linhas, qx aos 70 anos caiu de 0,02437 para 0,02093 (direção esperada). Desvio deliberado do "SIM+IBGE" original — usa as tábuas prontas do IBGE em vez do microdado bruto do SIM, mesmo resultado sem a fragilidade do pysus. 19 testes novos (<code>tests/</code>), todos passando contra arquivos reais.	Desligamento/aposentadoria/invalid ez continuam premissa, não extraídos de RAIS/CAGED/AEPS. Sem Docker/psql neste ambiente para rodar <code>gerar_dataset.py</code> ponta a ponta contra o Postgres de verdade — só a lógica pura foi testada.
Passo 4 · cenários econômicos Carlos / Paulo	feito	Coletores reais auditados (<code>app/data_sources/bacen.py</code> , <code>ibovespa.py</code>): 6 séries do SGS, snapshot imutável com <code>manifest.json</code> , hash SHA-256 por arquivo, escrita atômica, chunking correto do limite de 10 anos do SGS. Artefato de calibração versionado (<code>build_calibration.py</code>) combina os snapshots numa série histórica anual auditada; nunca sobrescreve versão publicada. Contrato de trajetória 0.2.0 integrado ao gerador/API/banco, convivendo com o contrato sintético 0.1.0 antigo. 88 testes : localmente 59 passaram e 29 foram pulados por falta de dependência; em Docker completo com PostgreSQL real, os 88 passaram , incluindo teste opt-in contra a API ao vivo do Bacen e do Yahoo Finance.	API ainda não lê o artefato de calibração automaticamente pelo hash — hoje é passo manual (documentado como limite, não escondido). Regras de ajuste (base/adverso/favorável) continuam deltas sintéticos declarados, não calibrados por volatilidade real. Implantação em servidor adiada por decisão do grupo.
ANBIMA / ETTJ	bloqueado	Spike probado contra a API ao vivo — a própria tentativa de validação é o resultado: a resposta observada não bateu com o contrato esperado do spike.	Não promovida a fonte de produção. <code>source_status: experimental-spike</code> — correto não forçar isso como dado confiável só porque a API respondeu algo.

FRENTE	STATUS	FEITO E VERIFICADO	PENDENTE
Passo 5 · tábua própria Maria Clara / Guilherme	feito	Pipeline completa já existia e roda (taxas brutas, coortes, suavização, aderência, credibilidade, IC, validação temporal, tábua própria). <code>comparacao_ae.py</code> reescrito: BR-EMS agora é a referência principal (<code>razao_ae_brems</code>), IBGE rebaixado a diagnóstico explícito (<code>razao_ae_ibge_diagnostico</code>) — Risco 02 resolvido. BR-EMS não publica tábua "Ambos": documentado como limitação, a categoria Ambos só existe no diagnóstico IBGE. 8 testes novos, todos passando (2 contra os arquivos reais de BR-EMS/IBGE, confirmando que as duas tábuas divergem o suficiente pra justificar ter uma principal e uma diagnóstico).	Sem Docker/psql neste ambiente para rodar <code>comparacao_ae.py</code> ponta a ponta contra o Postgres de verdade — só <code>calcular_ae()</code> foi testada isolada. Falta a equipe rodar o pipeline completo no ambiente Docker deles pra confirmar os portões de qualidade com os dados de verdade.
Passo 6 · geracional Danielle / Maria Eduarda	feito	Pipeline inteiro (5 etapas: série temporal, Mann-Kendall, estacionariedade, backtest, tábua geracional) já existia e rodava, mas a fonte de tendência estava priorizada errada. Corrigido: <code>carregar_historico_mortalidade()</code> agora usa a série real do IBGE (2015–2024, prioridade 1) e o HMD como challenger internacional (prioridade 2); o Postgres virou último recurso, rotulado explicitamente como sem tendência real. Rodado o pipeline inteiro de verdade: resultado real e honesto agora é queda de mortalidade estatisticamente significativa (Mann-Kendall, $p=0,0073$), baseado em dado brasileiro real, não mais dependente do Postgres estar ligado por acaso. 9/9 testes passando. Contrato para Passos 7/8 construído: <code>contracts/api_modelos.py</code> (<code>obter_parametros_para_passo7</code>/<code>obter_dados_para_passo8</code>) e <code>tabua_geracional.schema.json</code>, que estavam documentados em <code>interfaces_interpassos.md</code> mas não existiam. Testado de verdade: 12 testes novos do contrato Python (contra a série real) + schema validado contra as 1.581 linhas de um CSV real gerado pela pipeline — 0 falhas.	Nenhuma pendente neste item. Segue só o mesmo limite geral: rodar o pipeline completo contra o Postgres real da equipe.
Passos 2, 7/8	sem mudança	Passo 2 já tinha os 6 ajustes metodológicos de uma revisão anterior (validação temporal, multicolinearidade, submassa no KM etc.) — segue valendo.	Passo 2 não foi re-executado sobre a massa calibrada ainda. Passos 7/8 não foram iniciados.

FRENTE	STATUS	FEITO E VERIFICADO	PENDENTE
Documentação do repositório	feito	Varredura completa: README.md da raiz (só tinha o título) virou índice real com tabela de pastas/passo/dupla. Corrigidos 3 documentos com informação desatualizada: experiment_record.md do Passo 5 (ainda citava só IBGE), experiment_record.md do Passo 6 (caminhos de script de antes da reorganização em subpastas) e interfaces_interpassos.md (links absolutos quebrados apontando pra máquina de outro dev, módulo documentado como existente sem estar). O relatório de atividades antigo (docs/relatorio-atividades-tribo3.md) ganhou aviso de snapshot desatualizado em vez de reescrita completa.	Nenhuma pendente identificada nesta varredura além do que já está listado nas outras linhas desta tabela.

Riscos metodológicos — não pular estes

O esqueleto do plano está certo; estes quatro pontos são onde ele quebra se implementado ao pé da letra.

01 Calibração não é trocar uma constante

CRÍTICO

O PROBLEMA

O gerador sorteia status_atual uma vez, com peso global fixo. Um qx real varia de ~0,1% aos 25 anos a ~15% aos 85 — plugar a tabela real num sorteio único ignora a idade por completo.

A CORREÇÃO

Simular ano a ano desde o ingresso, sorteando morte/sobrevivência a cada ano com o qx da idade daquele ano. Encaixa com o desenho que já existe: exposicao já é uma linha por ano civil.

02 Circularidade na validação A/E

CRÍTICO

O PROBLEMA

Se o Passo 1 gera óbitos com o qx do IBGE e o Passo 5 valida comparando contra o mesmo IBGE, a comparação deixa de testar realidade — vira um teste de que o código simulou certo o que ele mesmo recebeu como insumo.

A CORREÇÃO

Calibrar com SIM+IBGE, validar com BR-EMS como referência principal — mesmo universo demográfico brasileiro, não só fonte independente. SOA RP-2014 é mortalidade de planos de pensão americanos: resolve a circularidade, mas não é equivalente a BR-EMS como benchmark demográfico — usar só como referência internacional complementar, nunca como substituto. Alternativa: declarar um fator de seleção explícito sobre o IBGE (ex.: 0,85× o qx).

03 Cenário econômico não é zero síntese

ATENÇÃO

O PROBLEMA

A calibração histórica (Selic, IPCA, ETTJ) é 100% real — mas ninguém tem dado real do futuro. Chamar a trajetória projetada de 'real' confunde calibração com previsão.

A CORREÇÃO

Ancorar o cenário determinístico na curva a termo (ETTJ) da ANBIMA — ela já embute a expectativa real do mercado hoje. Documentar: calibração é dado observado; trajetória é sempre modelo.

04 Reidentificação vira uma seção de verdade

ATENÇÃO

O PROBLEMA

Com tudo sintético, a seção de ameaças de reidentificação dos model cards (Passo 7/8) era quase pro forma.

A CORREÇÃO

SIM é óbito real (mesmo anonimizado); ELSI-Brasil, se usado, é dado pessoal de gente real. Essa análise passa a ter conteúdo de verdade para reportar à Tribo 4.

Catálogo de fontes

Como achar, o que a Tribo 3 usa de cada uma, e por quê.

Mortalidade e exposição

SIM — Sistema de Informações sobre Mortalidade

REAL

COMO ACHAR

dadosabertos.saude.gov.br/dataset/sim (URL antiga em opendatasus.saude.gov.br agora redireciona pra home, corrigido nesta revisão) · basedosdados.org (BigQuery) · pacote `pysus` · licença **CC BY-ND 3.0** (exige atribuição, proíbe redistribuir versão derivada — confirmado na fonte, ver Termos de uso)

USO · POR QUÊ

Não integrado nesta rodada. Óbitos individuais por idade/sexo/data seriam o numerador real do qx, mas a calibração do Passo 1 e o challenger histórico do Passo 6 usam a Tábua Completa do IBGE (linha abaixo) em vez disso — o IBGE já publica o qx pronto, sem precisar processar o microdado bruto do SIM (arquivos DBC por UF/ano, formato frágil, fonte do erro de sintaxe do `pysus` já documentado). Continua cadastrado como fonte real disponível se um dia for preciso segmentar por variável que a tábua pronta não cobre.

IBGE — Projeções da População

REAL

COMO ACHAR

API sem cadastro: servicodados.ibge.gov.br/api/v1/projeco/populacao/{localidade} · SIDRA, tabela 7358 (População por sexo e idade) ou 6706 (Pirâmide etária)

USO · POR QUÊ

População por idade/sexo/ano, 2000–2070. Seria o denominador se o qx fosse calculado a partir do SIM bruto; não usado nesta rodada pelo mesmo motivo do SIM acima.

IBGE — Tábua Completa de Mortalidade

REAL

COMO ACHAR

Arquivo para baixar, sem API:
[ftp.ibge.gov.br/Tabuas_Completas_de_Mortalidade](ftp://ftp.ibge.gov.br/Tabuas_Completas_de_Mortalidade)

USO · POR QUÊ

Papel ampliado nesta rodada. Já em uso no Passo 3 (benchmark A/E diagnóstico). Agora também calibra o qx do gerador do Passo 1 (`calibracao.py`, edição 2024) e alimenta o challenger nacional do Passo 6 em série histórica (`extrator_ibge_historico.py`, 2015–2024) — assumindo o papel que o plano original reservava pro SIM.

HMD, BR-EMS, SOA RP-2014

REAL

COMO ACHAR

mortality.org (HMD) · SUSEP/FenaPrevi (BR-EMS) · mort.soa.org (SOA) — já baixados em [ambiente-de-dados/docs/referencias/](#)

USO · POR QUÊ

Já em uso no Passo 3. Se o Passo 1 calibrar com SIM+IBGE, BR-EMS vira a validação principal (mesmo universo demográfico brasileiro); SOA (mortalidade de planos americanos) fica só como referência internacional complementar, não substituto (risco 02).

Cenários econômicos

Banco Central — SGS

REAL

COMO ACHAR

API sem cadastro:
api.bcb.gov.br/dados/serie/bcdata.sgs.{codigo}/dados ·
dadosabertos.bcb.gov.br

USO · POR QUÊ

Selic (11/432), IPCA (433), CDI (12), IGP-M (189), câmbio (1) — a base de qualquer cenário econômico do Passo 4.

ANBIMA — ETTJ

REAL

COMO ACHAR

anbima.com.br/informacoes/est-termo (endpoint legado confirmado com buraco de profund. histórica) ·
alternativa testada: pacote pyettj, que hoje puxa a curva de futuros de DI direto da B3, não mais do endpoint da ANBIMA

USO · POR QUÊ

Curva de juros real e nominal — ancora o cenário determinístico na expectativa de mercado observada hoje (risco 03).

Ibovespa / renda variável

REAL

COMO ACHAR

Sem API oficial gratuita da B3 — pacote yfinance, ticker ^BVSP

USO · POR QUÊ

Retorno de renda variável para cenários CD/CV. Não é catálogo governamental oficial — declarar isso na documentação.

IPEA Data

REAL

COMO ACHAR

API OData: ipeadata.gov.br/api/odata4/ValoresSerie(SE RCODIGO=...)

USO · POR QUÊ

Backup para série que não exista no SGS do Bacen, ou histórico mais longo.

Contexto de domínio e sobrevivência individual

PREVIC — Painei-Cidadão

REAL

COMO ACHAR

gov.br/previc · Painei-Cidadão — sem cadastro

USO · POR QUÊ

270 EFPCs e 1.180 planos (BD/CD/CV), atualizado mensalmente — valida a proporção de tipos de plano assumida no gerador sintético.

ELSI-Brasil

ALTERNATIVA, COM RESSALVA

COMO ACHAR

elsi.cpqrr.fiocruz.br — exige cadastro

USO · POR QUÊ

Única coorte brasileira real com estrutura individual de entrada/óbito (50+). As 3 ondas transversais não vêm prontas para empilhar como painel.

Itens a verificar antes de citar como fato

Vieram de resultados de busca web (resumo de mecanismo de busca), não de leitura direta da fonte primária por alguém da Tribo 3. Não são invenção — são o nível de confiança real que esse documento tem sobre eles hoje.

- **Corrigido nesta revisão:** a tabela do SIDRA citada antes (6579) era 'Estimativas de População' — total por município/UF, sem quebra por idade e sexo. As tabelas certas para o denominador do qx são **7358** (População por sexo e idade) ou **6706** (Pirâmide etária) — já atualizado no catálogo acima.
- **Confirmado, mas muda todo mês:** PREVIC Paineis-Cidadão — '270 EFPCs e 1.180 planos' bate com múltiplas fontes na data de lançamento (set/2025), mas o próprio painel já mostrava ~1.200 planos em mar/2026. Não hardcodear esse número em nenhum script — sempre consultar o painel ao vivo.
- **Verificado (30/set/2026):** o pacote pyetj foi instalado e testado ao vivo. Achado importante: a versão publicada hoje (0.4.2) **não consulta mais o endpoint da ANBIMA** — usa a B3 diretamente (curva de futuros de DI). Funcionou nas 4 datas testadas, incluindo duas em que o endpoint legado da ANBIMA devolveu vazio. O endpoint da ANBIMA em si foi confirmado com problema real de profundidade histórica (não só a data isolada já registrada) — ver spike atualizado em `cenarios-economicos/spikes/anbima_etj/README.md`.
- **Trecho removido por não bater com nenhuma versão real:** a sintaxe do pysus que estava no apêndice (SIM(), .get_files(), .download().to_dataframe()) nessa combinação exata veio de um resumo de busca gerado por IA, não da documentação primária — e não bate com nenhuma das versões reais do pacote (nem a legada, nem a atual namespaced, nem a baseada em classe). Rodar `pip show pysus` e ler a documentação da versão instalada antes de escrever qualquer chamada.
- **Ainda não verificado:** ELSI-Brasil — a ressalva sobre as 3 ondas transversais não empilharem como painel veio do próprio site do estudo; confirmar diretamente com a equipe antes de descartar essa fonte por causa disso.

Governança dos novos dados reais

§

Estender a prática que o Passo 3 já usa em `ambiente-de-dados/docs/referencias/` (baixar, versionar o arquivo bruto, registrar data de consulta) e que o Passo 5 já usa em `registro.py` (hash do dataset, commit git, versão de libs): toda vez que uma série do Bacen, SIM ou IBGE for puxada para calibrar alguma coisa, salvar o snapshot bruto com data — nunca confiar que a API vai devolver o mesmo valor depois.

Termos de uso — distinto de reidentificação

O Risco 04 cobre ameaça a terceiros (reidentificação); isto aqui é obrigação contratual de uso, uma coisa diferente. **SIM/OpenDataSUS (confirmado direto na fonte, 30/set/2026):** licença **Creative Commons Atribuição-SemDerivações 3.0 (CC BY-ND)**, não uma licença genérica permissiva como o catálogo assumia antes — exige declarar a fonte (Ministério da Saúde) e proíbe redistribuir versões derivadas/modificadas do dado. Isso só vira questão de verdade se o Passo 1 vier a usar SIM bruto no futuro (hoje não usa — ver desvio SIM→IBGE no catálogo). **ELSI-Brasil (confirmado direto na página oficial de acesso, 30/set/2026):** exige cadastro com aprovação de proposta de pesquisa pela equipe do estudo (não é só um cadastro automático); proíbe explicitamente disponibilizar os dados pra terceiros ou permitir qualquer acesso de terceiro aos arquivos; acesso é estritamente individual (cada pessoa do projeto baixa por conta própria); quebra de termo pode revogar o acesso e exigir apagar todas as cópias. Isso já basta pra dizer: **só estatísticas agregadas/derivadas podem ir para o repositório público da Tribo 3, nunca a base bruta baixada** — nenhum membro da equipe pode simplesmente repassar o arquivo baixado pros colegas. **Não confirmado** nessa checagem: uma cláusula de restrição a uso didático/curso que apareceu num resumo de busca por IA, mas não na página oficial de condições de uso que foi lida diretamente — mesma disciplina já aplicada ao caso do pysus: não tratar um resumo de busca como fonte primária.

Antes de confiar em qualquer script novo deste pivô

O mesmo processo usado para revisar este documento e o Passo 2 — não só para o apêndice de exemplo, para **qualquer** script novo que sair desta migração (extrator SIM+IBGE, gerador reformulado, coleta do Passo 4 de verdade).

- **Escrever teste** para os casos de borda de verdade (data no limite dos 10 anos do SGS, série vazia, participante sem correspondência na tabela real, etc.) — não só o caminho feliz.
- **Rodar contra a API/banco de verdade**, não só com dado sintético em memória. Um exemplo que só foi testado com dados fabricados na hora pode esconder um erro que só aparece com o volume, o formato ou a latência real da fonte.
- **Olhar o resultado renderizado**, não só confiar que compilou ou que a extração de texto parece certa — a extração de texto de um PDF, por exemplo, pode mostrar um caractere correto mesmo quando ele não renderiza direito visualmente (foi exatamente o que aconteceu neste próprio documento, com os símbolos Unicode que viraram quadrado preto).

Apêndice — exemplo de script (Passo 4)

Ainda não existe no repositório — era só uma ideia discutida em conversa, não um arquivo real. Já passou por 3 rodadas de correção (janela de data que estourava o limite do SGS, tratamento de erro que tinha sido cortado, sintaxe de pysus que não bateu com nenhuma versão real do pacote) — trate como rascunho de referência, não como código pronto para copiar e rodar sem testar. Versão condensada — visualização e o fallback do IPEA seguem o mesmo padrão e foram omitidos aqui por espaço. O script real de coleta fica a cargo da dupla do Passo 4, com testes próprios antes de confiar nos números.

```
"""
Coleta de dados publicos reais para a Tribo 3 -- cenarios economicos

Fontes com API JSON confirmada: Banco Central (SGS) e IBGE
(Projecoes da Populacao). A tabua completa de mortalidade do IBGE,
a populacao por sexo/idade do SIDRA e o SIM/DATASUS NAO tem API
JSON -- ver nota_fontes_sem_api().

Uso:
    pip install requests pandas
    python coletar_dados_publicos.py
"""

from datetime import date, datetime, timedelta
from pathlib import Path

import pandas as pd
import requests

PASTA_SAIDA = Path(__file__).resolve().parent / "docs" / "referencias"
PASTA_SAIDA.mkdir(parents=True, exist_ok=True)

# ----- Banco Central -- SGS -----
# Codigos confirmados: https://dadosabertos.bcb.gov.br

SERIES_BACEN = {
    "selic": 11,    # Taxa Selic diaria, % a.d.
    "ipca": 433,   # IPCA, variacao % mensal
    "cdi": 12,     # CDI diario, % a.d.
    "igpm": 189,  # IGP-M, variacao % mensal
    "dolar": 1,   # Dolar comercial, venda, diario
}

DIAS_POR_JANELA = 3640 # ~9,97 anos -- margem de seguranca sob o limite de 10 anos do SGS

def _blocos_de_data(inicio, fim, dias_por_bloco=DIAS_POR_JANELA):
    """Fatia [inicio, fim] em blocos de no maximo `dias_por_bloco` dias."""
    cursor = inicio
    while cursor <= fim:
        fim_bloco = min(fim, cursor + timedelta(days=dias_por_bloco))
        yield cursor, fim_bloco
        cursor = fim_bloco + timedelta(days=1)

def buscar_serie_bacen(codigo, data_inicial="01/01/2015", data_final=None):
    """Busca uma serie do SGS/Bacen. data_final default = hoje,
    nao um valor fixo que fica velho com o tempo.

    O SGS limita consultas a ~10 anos por requisicao -- rodar isso
    anos depois de 2015 com data_final=hoje estouraria esse limite,
    entao a janela e sempre fatiada em blocos seguros e concatenada,
    em vez de confiar que o intervalo pedido nunca vai passar de 10 anos.
    """
    inicio = datetime.strptime(data_inicial, "%d/%m/%Y").date()
    fim = (date.today() if data_final is None
           else datetime.strptime(data_final, "%d/%m/%Y").date())

    partes = []
    for ini_bloco, fim_bloco in _blocos_de_data(inicio, fim):
        url = (
            f"https://api.bcb.gov.br/dados/serie/bcdata.sgs.{codigo}/dados"
            f"?formato=json&dataInicial={ini_bloco:%d/%m/%Y}&dataFinal={fim_bloco:%d/%m/%Y}"
        )
```

```

    resposta = requests.get(url, timeout=30)
    resposta.raise_for_status()
    partes.append(pd.DataFrame(resposta.json()))

df = pd.concat(partes, ignore_index=True)
df["data"] = pd.to_datetime(df["data"], format="%d/%m/%Y")
df["valor"] = df["valor"].astype(float)
return df.sort_values("data").reset_index(drop=True)

# ----- IBGE -- API de Projecoes da Populacao -----

def buscar_projecao_populacao_ibge(localidade="BR"):
    """Projecao da populacao do IBGE. localidade: 'BR', regiao
    (1 a 5) ou codigo numerico da UF."""
    url = f"https://servicodados.ibge.gov.br/api/v1/projecoes/populacao/{localidade}"
    resposta = requests.get(url, timeout=30)
    resposta.raise_for_status()
    return pd.json_normalize(resposta.json())

def coletar_tudo():
    dados = {}
    for nome, codigo in SERIES_BACEN.items():
        # Cada serie e independente -- uma falhar nao pode derrubar as outras.
        try:
            df = buscar_serie_bacen(codigo)
            df.to_csv(PASTA_SAIDA / f"bacen_{nome}.csv", index=False)
            dados[nome] = df
            print(f" {nome}: {len(df)} registros salvos")
        except requests.RequestException as erro:
            print(f" falhou ao buscar {nome}: {erro}")

    try:
        dados["projecao_populacao"] = buscar_projecao_populacao_ibge("BR")
        dados["projecao_populacao"].to_csv(
            PASTA_SAIDA / "ibge_projecao_populacao.csv", index=False)
    except requests.RequestException as erro:
        print(f" falhou ao buscar projecao do IBGE: {erro}")
    return dados

def nota_fontes_sem_api():
    """
    Sem API JSON -- nao incluidas na coleta automatica acima:

    1. IBGE -- Tabuas Completas de Mortalidade (Passo 3)
       ftp.ibge.gov.br/Tabuas_Completas_de_Mortalidade/

    2. IBGE -- Populacao por sexo e idade (denominador do qx)
       SIDRA tabela 7358 ou 6706 -- a 6579 e so populacao total,
       sem quebra por idade/sexo, nao serve para isso.

    3. DATASUS/SIM (obitos) -- via pacote pysus. A sintaxe exata
       MUDOU pelo menos 2 vezes nas ultimas versoes da lib -- nao
       hardcodar nenhum snippet aqui sem antes rodar `pip show
       pysus` e ler a documentacao da versao instalada de verdade
       (ver "itens a verificar" no corpo do documento).

    4. ANBIMA -- ETTJ (curva de juros), via pacote pyettj
       (ainda nao testado pela Tribo 3).
    """

if __name__ == "__main__":
    coletar_tudo()

```